ИТОГОВЫЙ ПРОЕКТ · АВТОМАТИЗИРОВАННЫЙ СБОР ДАННЫХ

Гибридный пайплайн сбора данных: два учебных магазина

ЦЕЛЬ

Построить воспроизводимый пайплайн: собрать данные из HTML-сайта и REST API, очистить, проверить качество, сохранить в базу и ответить на исследовательский вопрос

ВОПРОС

Как соотносятся цены и ассортимент scrapingcourse.com и DummyJSON в общих товарных группах? Связаны ли цена и скидка с рейтингом и отзывами?

Пермь, 2026г

ШАГ 0 · ПАСПОРТ ДАННЫХ

Два источника разной природы

Параметр	HTML · scrapingcourse.com/ecommerce	API · dummyjson.com/products
Что это	Магазин одежды и спорта (WooCommerce)	Учебный магазин, 24 категории
Инструмент	requests + BeautifulSoup	requests, ответ в JSON
Пагинация	ссылка «next» → /page/2/ … /page/12/	limit=50 и skip до поля total
Объём	188 товаров: 12 страниц + 188 карточек	194 товара и 582 отзыва
Что берём	цена, скидка, категории, наличие	цена, скидка, бренд, рейтинг, отзывы
Ключ	slug товара из адреса страницы	id товара
Экономия	sha256 страницы, sitemap, водяной знак	ETag → ответ 304
Перс. данные	нет	имя и e-mail в отзывах — удаляем

Связь источников: каждому товару назначается единая товарная группа. Общие группы: tops, bags, watches, fitness.

ПАЙПЛАЙН СИСТЕМЫ

Шесть этапов — шесть файлов

config.yaml - настройки для всех этапов: адреса, паузы, повторы, пороги качества, правила групп

1 · Диагностика
`diagnose.py`
нужен ли браузер, robots.txt

→

2 · Сбор
`collect_html.py`
`collect_api.py`
→ raw/

→

3 · Очистка
`clean.py`
`contract.py`
→ clean/

→

4 · Качество
`quality.py`
11 метрик, светофор

→

5 · Хранилище
`storage.py`
`schema.sql`
→ SQLite, mart/

→

6 · Анализ
`analysis.ipynb`
графики, выводы

run_pipeline.py - одна команда запускает этапы 2–5 по порядку. Каждый источник собирается отдельно: отказ одного не роняет другой

http_client.py - все запросы: пауза ≥ 1 с, robots.txt, повтор временных ошибок, Retry-After, предохранитель

ЭТАПЫ 2–4 · ЧТО ПРОИСХОДИТ С ДАННЫМИ

raw → clean → проверка качества

raw/ — сырые данные

collect_html.py · collect_api.py

Записи «как пришли», файлы JSON Lines. Только дозапись. У строки: источник, время, номер прогона

188 записей HTML, 194 товара API + 582 отзыва

clean/ — чистые данные

clean.py · contract.py

Цены → числа, товару назначается группа, наличие — по вариациям. Контракт pydantic: типы, диапазоны, 8 своих проверок

382 товара + 582 отзыва в Parquet, отброшено 0

Проверка качества

quality.py

11 метрик с порогами: объём, дубли, пропуски, выбросы, связь источников. Светофор GREEN / YELLOW / RED

Итог: YELLOW — выбросы цены 6,8 % (дорогие часы в API). RED → в базу не пишем

Повторный запуск: 21 запрос вместо ~210 · вставок 0 · дублей 0 · продолжает после обрыва

ЭТАП 5 · БАЗА ДАННЫХ

Где хранятся итоговые данные

База SQLite - один файл **db/warehouse.db**. Устроена как книга Excel: несколько листов-таблиц, связанных между собой

Таблица products

Товары · 382

Товары обоих магазинов: цена, скидка, группа, рейтинг. У каждого постоянное имя: «магазин:товар»

Таблица reviews

Отзывы · 582

Оценка и текст. Каждый отзыв ссылается на свой товар из таблицы «Товары»

Служебные таблицы

История и журнал

Когда менялась цена товара и как прошёл каждый запуск — чтобы сравнивать с прошлым днём

При каждом запуске - три правила, поэтому дублей нет:

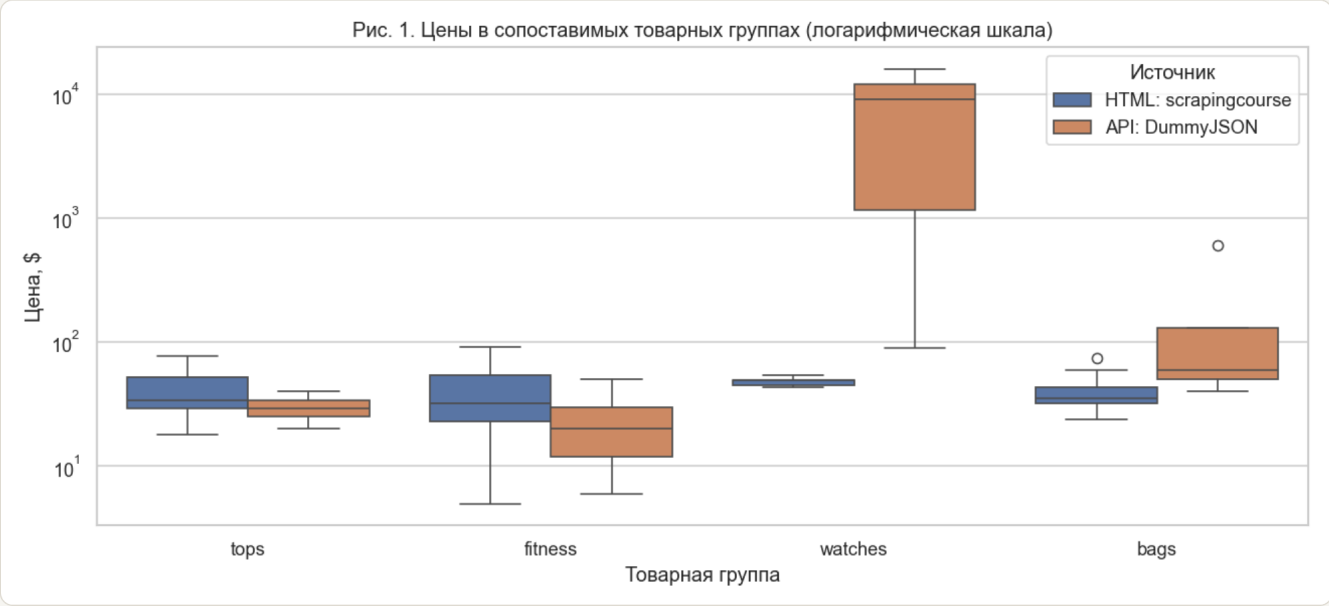
Новый товар → добавить

Изменился → обновить

Не изменился → не трогать

ЭТАП 6 · АНАЛИЗ · ВОПРОС 1

Цены и ассортимент: единой картины нет



Группа	API / HTML
fitness	× 0.62 дешевле
tops	× 0.85 дешевле
bags	× 1.71 дороже
watches	× 184

Отношение медианных цен. Различие значимо во всех группах (Манн — Уитни, $p < 0.05$)

Цены: в одежде и фитнесе DummyJSON дешевле, сумки дороже, а часы - другой сегмент: премиальные до $16 000 против спортивных за $43–54

Ассортимент: 67 % HTML-магазина - одежда и фитнес; 70 % товаров DummyJSON - в категориях, которых во втором магазине нет

ЭТАП 6 · АНАЛИЗ · ВОПРОС 2

Цена и скидка с рейтингом не связаны

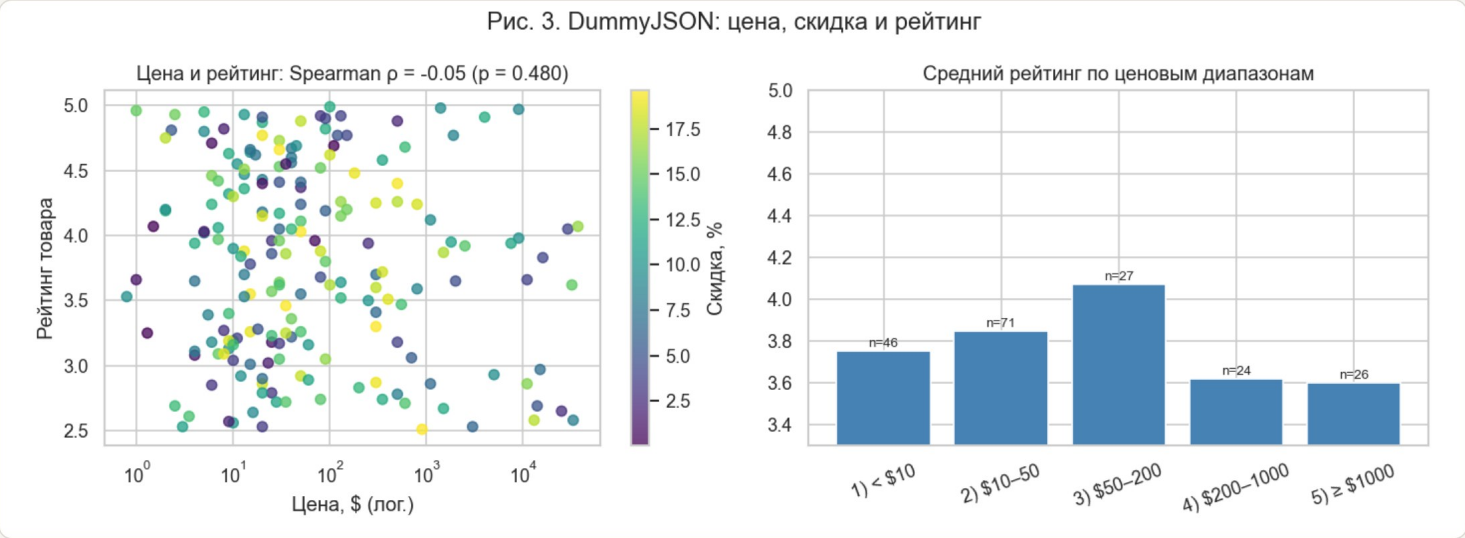


Рис. 3. DummyJSON: цена, скидка и рейтинг

Связь	ρ	p
Цена – рейтинг	−0.05	0.48
Скидка – рейтинг	−0.00	0.98
Рейтинг – отзывы	−0.07	—

ρ — корреляция Спирмена: около 0 — связи нет; p > 0.05 — незначимо

Результат: дорогие и дешёвые товары, со скидкой и без, получают одинаковые оценки; средняя оценка 3 отзывов не совпадает с рейтингом товара

Почему: DummyJSON - учебный синтетический набор; судя по нулевой связи, цены, скидки и рейтинги в нём заданы независимо

ВЫВОД

Ответы на вопрос и правовая часть

Цены и ассортимент

Соотношение зависит от группы: одежда и фитнес дешевле в DummyJSON, сумки дороже, часы — разные сегменты. Ассортимент пересекается лишь в 4 группах

Цена, скидка и рейтинг

Связи нет ($\rho \approx 0$, незначимо). Рейтинг не следует и из отзывов — признак синтетических данных

Правовая часть

Учебные площадки, без авторизации и обхода защиты, ≤ 1 запрос/с, контакт в User-Agent. Имена и e-mail из отзывов удаляются. robots.txt запрещает /ecommerce/* — явное исключение для учебного сайта, видно в логах

Ограничения

Синтетические каталоги, малые выборки в общих группах (от 5 товаров), группы назначаются правилами, рейтинг есть только у API

NO-CODE · N8N

Тот же сбор — нодами n8n

